

BAB I PENDAHULUAN

1.1 Latar Belakang

Asuransi kesehatan individu merupakan instrumen kritis dalam manajemen risiko finansial modern. Produk ini melindungi pemegang polis dari beban biaya medis tak terduga, mulai dari rawat jalan hingga rawat inap berbiaya tinggi. Di Indonesia, kesadaran akan pentingnya proteksi kesehatan terus meningkat, mendorong pertumbuhan nasabah asuransi secara signifikan.

Namun, industri asuransi kesehatan individu kini menghadapi tantangan serius, yakni tekanan klaim yang terus meningkat dengan pola yang semakin kompleks dan sulit diprediksi secara konvensional. Kondisi ini memberikan tekanan pada keuntungan perusahaan sekaligus keterjangkauan premi bagi nasabah. Diperlukan pendekatan analitik berbasis data yang mampu memprediksi tren klaim secara akurat guna mendukung pengambilan keputusan strategis dalam pengelolaan risiko, penetapan premi, dan program pencegahan klaim.

Dataset kompetisi ini mencakup 4.096 data polis aktif dan 4.627 data klaim berstatus PAID untuk periode 1 Januari 2024 – 31 Juli 2025. Distribusi nominal klaim sangat right-skewed dengan median Rp14,4 juta dan nilai maksimum Rp2,2 miliar sebelum winsorisasi, mengindikasikan keberadaan klaim katastrofe yang perlu ditangani secara khusus dalam pemodelan. Dari segi profil risiko, nasabah berusia di atas 60 tahun mendominasi dengan 48,7% total klaim.

1.2 Rumusan Masalah

1. Faktor apa yang paling memengaruhi severitas (besaran nominal) klaim asuransi kesehatan individu?
2. Faktor apa yang paling memengaruhi frekuensi klaim asuransi kesehatan individu?
3. Bagaimana membangun model machine learning yang akurat untuk memprediksi tren frekuensi, severitas, dan total nominal klaim?
4. Model mana yang memberikan performa terbaik untuk prediksi time series klaim asuransi?
5. Bagaimana rekomendasi strategis bagi AXA Financial Indonesia berdasarkan hasil prediksi 2026?

1.3 Tujuan

6. Melakukan eksplorasi dan pembersihan data klaim secara komprehensif.
7. Mengidentifikasi faktor-faktor paling berpengaruh terhadap severitas dan frekuensi klaim.
8. Membangun dan mengevaluasi tiga model machine learning untuk prediksi tren klaim.
9. Menghasilkan prediksi klaim 17 bulan ke depan beserta prediction interval dan rekomendasi actionable bagi AXA Financial Indonesia.

BAB II METODOLOGI

2.1 Data

2.1.1 Sumber Data

Dataset bersumber dari AXA Financial Indonesia, disediakan khusus untuk kompetisi DSC MCF ITB 2026. Terdapat dua tabel: (1) Data Polis dengan 4.096 baris dan 6 kolom (Nomor Polis, Plan Code, Gender, Tanggal Lahir, Tanggal Efektif Polis, Domisili); (2) Data Klaim dengan 5.781 baris yang setelah pemfilteran status PAID menghasilkan 4.627 klaim valid dengan 13 kolom meliputi informasi klinis dan administratif lengkap. Data mencakup periode klaim Januari 2024 – Juli 2025 (19 bulan observasi).

2.1.2 Preprocessing & Winsorisasi

Preprocessing meliputi beberapa tahapan: (1) parsing tanggal dari format integer (YYYYMMDD) ke datetime; (2) identifikasi missing values — 37 baris pada Inpatient/Outpatient dan Tanggal Pembayaran, 6 baris pada ICD Diagnosis, dan 7 baris pada Lokasi RS; (3) drop 37 baris dengan data medis tidak lengkap; (4) winsorisasi batas bawah 1% dan batas atas 99% pada nominal klaim (rentang valid: Rp187.242 – Rp633.686.130) untuk mereduksi dampak outlier ekstrem tanpa menghilangkan data; (5) merge Data Polis ke Data Klaim melalui Nomor Polis untuk enrichment demografis.

2.1.3 Feature Engineering

Feature engineering dilakukan dalam dua tahap. Pertama, pada level klaim individual: kalkulasi usia saat klaim, Length of Stay, dan variabel tipe layanan. Kedua, agregasi ke 19 titik data bulanan menghasilkan empat kelompok fitur sebagaimana ditunjukkan pada Tabel 1.

Kelompok	Fitur	Keterangan
Temporal	Time_Index, Month, Quarter	Indeks waktu dan kalender
Cyclical	Month_Sin, Month_Cos, Quarter_Sin, Quarter_Cos	Encoding siklus tanpa diskontinuitas
Lag	Freq/Sev/Total_Lag_1,2,3	Autokorelasi hingga 3 bulan
Rolling	Rolling_Mean/Std_3/6	Statistik bergulir 3–6 bulan
Exposure	Active_Polis	Anchor aktuarial — importance 0% karena portofolio stabil 4.096 polis; dipertahankan untuk skenario portofolio berubah

Tabel 1. Kelompok Fitur Engineering per Target

Jumlah fitur aktif per target: Claim Frequency 12 fitur, Claim Severity 12 fitur, Total Claim 11 fitur. Exposure dipertahankan sebagai deliberate design decision untuk kompatibilitas aktuarial jangka panjang, meski feature importance 0% akibat tidak adanya variasi pada data historis.

Seasonal Naive dihitung sebagai rata-rata historis per bulan kalender. Untuk bulan dengan hanya 1 observasi, digunakan blending 50% nilai aktual + 50% rata-rata bulan sekitarnya — bukan metode Lag-12 — untuk mengurangi sensitivitas terhadap single data point.

2.2 Model yang Digunakan

Tim mengimplementasikan tiga model yang dikombinasikan dalam arsitektur ensemble:

- Prophet (Taylor & Letham, 2018): model time series additive dari Meta dengan konfigurasi `yearly_seasonality=False`, `seasonality_mode='additive'`, `changepoint_prior_scale=0.01`. Nilai CPS 0.01 divalidasi secara empiris melalui sensitivity analysis (Cell 4A) yang menguji nilai 0.001, 0.01, 0.05, dan 0.1 — CPS 0.01 terbukti optimal dengan MAPE rata-rata 4,79%.
- LightGBM (Ke et al., 2017): gradient boosting berbasis histogram dengan `n_estimators=200`, `learning_rate=0.05`, `max_depth=2`, `num_leaves=4`. Regularisasi ketat mencegah overfitting pada dataset 19 bulan. Unggul dalam menangkap interaksi fitur lag dan rolling statistics.
- Seasonal Naive: metode baseline berbasis rata-rata historis per bulan kalender dengan blending 50/50 untuk bulan dengan observasi tunggal. Berfungsi sebagai anchor stabilitas jangka panjang. Rasio blending 0.3, 0.5, dan 0.7 diuji melalui sensitivity analysis dan terbukti tidak material — MAPE identik untuk ketiga rasio.

2.3 Arsitektur Ensemble & Validasi

2.3.1 Walk-Forward Validation

Walk-forward validation dengan minimum training size 14 bulan menghasilkan 5 fold: Fold 1 (train: Jan 2024–Feb 2025, validasi: Mar 2025) hingga Fold 5 (train: Jan 2024–Jun 2025, validasi: Jul 2025). Pendekatan ini menghindari data leakage temporal dan menghasilkan estimasi performa yang mencerminkan kondisi deployment nyata, di mana model hanya dapat menggunakan data historis untuk prediksi ke depan.

2.3.2 Bobot Ensemble & Progressive Weighting

Bobot ensemble dihitung menggunakan metode inverse MAPE weighting secara independen per target. Model dengan MAPE lebih kecil mendapatkan bobot lebih besar secara proporsional. Pada fase prediksi 17 bulan, arsitektur progressive weighting membagi horizon menjadi tiga zona:

- Zona ML (langkah 0–4, Agt–Des 2025): bobot ML 90%, Naive 10% — lag features masih dekat dengan data aktual.
- Zona Balance (langkah 5–10, Jan–Jun 2026): bobot ML menurun linear dari 90% ke 50% — transisi bertahap seiring meningkatnya uncertainty.
- Zona Naive (langkah 11–16, Jul–Des 2026): bobot Naive meningkat hingga 80% — memanfaatkan stabilitas pola musiman untuk horizon jauh.

2.3.3 Sensitivity Analysis Hyperparameter

Dua keputusan hyperparameter yang sebelumnya dipilih secara konservatif divalidasi secara empiris melalui Cell 4A. Pertama, `changepoint_prior_scale` Prophet diuji pada 4 nilai (0.001, 0.01, 0.05, 0.1) dengan `fourier_order=3` fixed — CPS 0.01 terbukti optimal, selisih antar nilai hanya 0,02–0,05%. Kedua, blending ratio Seasonal Naive diuji pada 3 rasio (30/70, 50/50, 70/30) — ketiga rasio menghasilkan MAPE identik 4,79%, menunjukkan model insensitif terhadap pilihan rasio.

2.3.4 Prediction Interval & Backtesting Coverage

Prediction interval dibangun menggunakan block bootstrap pada hybrid residual pool: OOS residual (3×) + IS residual (1×) = 34 poin, 17 blok, `block_size=2`, `n=500` iterasi, menghasilkan 80% CI (P10–P90). IS residual dihitung dengan bobot ensemble per-langkah (progressive weights) agar konsisten dengan metodologi forecasting.

Validasi empiris coverage dilakukan melalui expanding window backtesting pada 9 window (Nov 2024–Jul 2025): untuk setiap window t , model dilatih pada bulan $1-t$, PI satu langkah ke depan dibangun, kemudian aktual bulan $t+1$ dicek apakah masuk dalam interval.

2.3.5 Metrik Evaluasi (MAPE)

MAPE (Mean Absolute Percentage Error) digunakan sebagai metrik utama karena fokusnya pada akurasi proporsional. Dalam bisnis asuransi, kesalahan prediksi 10% pada klaim besar jauh lebih signifikan dari pada 10% pada klaim kecil. Skor akhir adalah rata-rata sederhana dari MAPE_freq, MAPE_sev, dan MAPE_total.

BAB III HASIL DAN PEMBAHASAN

3.1 Eksplorasi Data (EDA)

3.1.1 Distribusi Klaim

Dari 4.627 data klaim yang dianalisis, seluruhnya berstatus PAID. Distribusi nominal klaim sangat right-skewed: mean Rp55,0 juta, median Rp14,4 juta, dan nilai maksimum Rp2,2 miliar sebelum winsorisasi. Sebaran metode pembayaran: 58,8% Reimburse (R) dan 41,2% Cashless (C). Berdasarkan tipe layanan, klaim terdistribusi atas empat kategori: Inpatient (IP) 2.258 klaim (48,8%), Outpatient (OP) 1.940 klaim (41,9%), ODC 281 klaim (6,1%), dan ODS 111 klaim (2,4%).

Statistik	Nilai	Statistik	Nilai
Total Klaim	4.627	Metode Reimburse	2.722 (58,8%)
Mean Nominal	Rp 55,0 juta	Metode Cashless	1.905 (41,2%)
Median Nominal	Rp 14,4 juta	Inpatient (IP)	2.258 (48,8%)
Maks Nominal (pre-winsorisasi)	Rp 2,2 miliar	Outpatient (OP)	1.940 (41,9%)

Tabel 2. Statistik Deskriptif Klaim

3.1.2 Analisis Demografis

Analisis demografis mengungkap pola risiko yang kuat. Dari segi gender, klaim terdistribusi hampir merata: perempuan 2.327 klaim (50,3%) dan laki-laki 2.300 klaim (49,7%). Uji Kruskal-Wallis mengkonfirmasi bahwa perbedaan gender tidak signifikan secara statistik ($H=1,23$, $p=0,268$).

Faktor usia menunjukkan pola yang sangat kuat dan signifikan ($H=190,42$, $p<0,001$): kelompok usia >60 tahun mendominasi dengan 2.251 klaim (48,7%), diikuti 46–60 tahun dengan 1.804 klaim (39,0%). Korelasi Spearman antara usia dan severitas menghasilkan $\rho=0,136$ ($p<0,001$). Berdasarkan plan code, hasil uji signifikan ($H=34,51$, $p<0,001$) dengan Plan M-003 mencatat median klaim tertinggi di antara semua plan.

3.1.3 Tren Bulanan

Data bulanan mencakup 19 observasi (Januari 2024–Juli 2025). Frekuensi klaim bulanan berkisar 208–302 dengan rata-rata ~242 klaim/bulan. Puncak tertinggi terjadi pada Januari 2024 (302 klaim, total Rp18,95 miliar). Titik terendah adalah Januari 2025 (<Rp10 miliar total) sebelum rebound di Februari 2025 (severitas Rp58,3 juta). Pola musiman klaim cenderung lebih tinggi di awal tahun (Q1).

Uji Kruskal-Wallis terhadap tipe layanan menunjukkan signifikansi tertinggi ($H=789,72$, $p<0,001$) dengan rasio median klaim Inpatient terhadap Outpatient mencapai 9,94 $\times$. Korelasi Length of Stay terhadap severitas $\rho=0,503$ ($p<0,001$) menjadikannya prediktor numerik terkuat pada level individual klaim.


3.2 Machine Learning Training

3.2.1 Perbandingan MAPE per Model

Evaluasi walk-forward validation (5 fold) menghasilkan perbandingan performa yang komprehensif. Seasonal Naive sebagai baseline justru mengungguli kedua model ML pada hampir semua dimensi — konsisten dengan karakteristik data time series pendek (19 observasi) di mana pola musiman tahunan mendominasi sinyal prediksi. Ensemble dengan bobot inverse MAPE berhasil memanfaatkan kelebihan ketiga model secara sinergis, menghasilkan MAPE rata-rata 4,79%.

Model	MAPE Frekuensi	MAPE Severitas	MAPE Total	Rata-rata
Prophet	14,36%	16,15%	16,00%	15,50%
LightGBM	7,00%	7,25%	7,84%	7,36%
Seasonal Naïve	5,23%	4,34%	3,82%	4,46%
Ensemble (Optimal)	6,76%	4,89%	2,72%	4,79%

Tabel 3. Perbandingan MAPE Model pada Walk-Forward Validation (5 Fold)



Gambar 3.1. Perbandingan MAPE per Model (bar chart per target)


3.2.2 Dampak Feature Engineering — Ablasi

Studi ablasi dilakukan dengan menghapus satu kelompok fitur setiap kali dan mengukur peningkatan MAPE rata-rata (Δ MAPE) dibandingkan model penuh. Hasil menunjukkan fitur lag memberikan dampak terbesar pada severitas (+4,57%) dan total klaim (+5,44%), sedangkan fitur cyclical paling kritis untuk frekuensi (+5,59%). Exposure tidak memberikan kontribusi (0,00%) karena tidak ada variasi pada portofolio stabil 4.096 polis — bukan karena tidak relevan secara aktuarial.

Kelompok Fitur	Δ MAPE Frekuensi	Δ MAPE Severitas	Δ MAPE Total	Rata-rata
Lag	+2,00%	+4,57%	+5,44%	+4,00%
Cyclical	+5,59%	+3,30%	+2,32%	+3,74%
Rolling	+3,18%	+0,36%	+5,05%	+2,86%

Kelompok Fitur	Δ MAPE Frekuensi	Δ MAPE Severitas	Δ MAPE Total	Rata-rata
Temporal	+1,15%	+0,13%	+0,18%	+0,49%
Exposure	0,00%	0,00%	0,00%	0,00%

Tabel 4. Hasil Ablasi Studi Δ MAPE saat Kelompok Fitur Dihapus



Gambar 3.2. Kenaikan MAPE saat Kelompok Fitur Dihapus (Ablasi Studi)

3.2.3 Bobot Ensemble & Feature Importance

Optimasi inverse MAPE weighting menghasilkan bobot yang berbeda per target, mencerminkan kekuatan relatif masing-masing model. Seasonal Naïve mendominasi semua target karena MAPE validasinya paling rendah.

Target	Bobot Prophet	Bobot LightGBM	Bobot Naïve
Frekuensi	0,173	0,354	0,473
Severitas	0,144	0,320	0,536
Total Klaim	0,138	0,282	0,580

Tabel 5. Bobot Ensemble per Target (Inverse MAPE Weighting)

Analisis permutation importance mengkonfirmasi hasil ablasi. Untuk frekuensi, Month_Sin menjadi fitur terpenting (+4,20% Δ MAPE saat dipermutasi), diikuti Freq_Std_3 (+3,12%) dan Month_Cos (+2,61%). Untuk severitas, Sev_Lag_2 (+4,96%) dan Month_Cos (+3,72%) memimpin. Untuk total klaim, Total_Rolling_3 (+5,55%) dan Total_Lag_2 (+5,50%) paling berpengaruh. Konsistensi antara ablasi dan permutation importance memperkuat validitas interpretasi model.

3.2.4 Sensitivity Analysis Hyperparameter


Sensitivity analysis (Cell 4A) memvalidasi dua keputusan hyperparameter secara empiris. Pertama, changepoint_prior_scale Prophet: CPS 0.01 terbukti optimal di antara 4 nilai yang diuji, dengan selisih terhadap nilai lain hanya 0,02–0,05% — menunjukkan model tidak sensitif terhadap

changepoint regularization, konsisten dengan data yang didominasi pola musiman flat-trend. Kedua, blending ratio Seasonal Naive: ketiga rasio (30/70, 50/50, 70/30) menghasilkan MAPE identik 4,79% — blending ratio tidak material karena jumlah bulan dengan 1 observasi sangat sedikit dalam 19 bulan data.

3.3 Hasil Prediksi

3.3.1 Forecast 17 Bulan dengan Prediction Interval

Model ensemble menghasilkan prediksi 17 bulan (Agustus 2025 – Desember 2026) dengan prediction interval 80% berbasis block bootstrap. P50 total klaim 2026 sebesar Rp143,49 miliar hampir identik dengan point estimate Rp143,00 miliar (selisih 0,3%), mengkonfirmasi bootstrap bersifat unbiased.




Gambar 3.3. Forecast Total Klaim 17 Bulan dengan 80% Prediction Interval (Block Bootstrap, Hybrid OOS 3x + IS 1x, n=500 iterasi)

Prediction interval Total Claim 2026: **P10 = Rp132,34 miliar, P50 = Rp143,49 miliar, P90 = Rp149,11 miliar**, lebar 80% PI = Rp16,78 miliar. P90 digunakan sebagai acuan cadangan teknis konservatif berbasis data, menggantikan buffer persentase arbitrary.

3.3.2 Backtesting Empirical Coverage

Validasi empiris coverage dilakukan melalui 9 expanding window backtesting. Hasilnya: PI Total Claim mencapai coverage 88,9% — melampaui target nominal 80%. Satu-satunya miss adalah Januari 2025, yang merupakan titik terendah historis terdokumentasi di EDA (anomali musiman ekstrem). PI Frequency dan Severity menunjukkan undercoverage 66,7% — interval terlalu sempit untuk dua target ini akibat volatilitas residual yang lebih tinggi.



Gambar 3.4. Empirical Coverage Rate Backtesting 9 Window (Nov 2024–Jul 2025)


Target	n Window	Coverage 80% PI	Coverage 90% PI	Keterangan
Total Claim	9	88,9% ✓	88,9%	Layak acuan cadangan aktuarial
Claim Frequency	9	66,7% △	77,8%	Indikatif — undercoverage
Claim Severity	9	66,7% △	88,9%	Indikatif — undercoverage

Tabel 6. Empirical Coverage Rate Prediction Interval

3.3.3 Ringkasan Prediksi 2026 per Kuartal

Kuartal	Rata-rata Frekuensi	Rata-rata Severitas	Total (Rp M)	P90 Cadangan (Rp M)
Q1 2026 (Jan–Mar)	227,8	Rp 49,18 juta	37,13	38,70
Q2 2026 (Apr–Jun)	228,9	Rp 49,90 juta	33,32	34,74
Q3 2026 (Jul–Sep)	237,3	Rp 50,37 juta	36,01	37,54
Q4 2026 (Okt–Des)	248,5	Rp 48,08 juta	36,55	38,13
Total 2026	235,6	Rp 49,38 juta	143,00	149,11

Tabel 7. Ringkasan Prediksi 2026 per Kuartal dengan P90 Cadangan



Gambar 3.5. Prediksi per Kuartal 2026: Point Estimate vs P90 Cadangan & Frekuensi

3.3.4 Analisis Tren & Perbandingan 2025 vs 2026

Perbandingan terannualisasi antara 2025 (7 bulan observasi Jan–Jul, diekstrapolasi $\times 12/7$) dan proyeksi 2026 menunjukkan stabilitas portofolio yang relatif baik.

Metrik	2025 Annualized	2026 Prediksi	Delta
Total Frekuensi	2.806 klaim	2.828 klaim	+0,8%
Rata-rata Severitas	Rp 50,93 juta	Rp 49,38 juta	-3,0%
Total Klaim	Rp 143,14 miliar	Rp 143,00 miliar	-0,1%

Tabel 8. Perbandingan 2025 Annualized vs Prediksi 2026

Penurunan tipis severitas rata-rata -3,0% konsisten dengan normalisasi setelah lonjakan Februari 2025. Total klaim hampir stagnan (-0,1%) mencerminkan portofolio yang stabil. Dari perspektif manajemen risiko, volatilitas antar bulan tetap perlu diwaspadai — pola ini mengindikasikan perlunya cadangan klaim yang fleksibel dan tidak bergantung pada rata-rata tahunan semata.

BAB IV PENUTUP

4.1 Kesimpulan

1. Model Ensemble Prophet-LightGBM-Seasonal Naïve dengan progressive weighting mencapai MAPE rata-rata 4,79%, mengungguli Prophet tunggal (15,50%), LightGBM tunggal (7,36%), maupun Seasonal Naïve tunggal (4,46%). Nilai tambah ensemble terletak pada kemampuannya menggabungkan kekuatan komplementer ketiga model.
2. Seasonal Naïve tampil sebagai komponen terkuat dalam ensemble karena data historis 19 bulan membuat pola musiman tahunan menjadi sinyal prediktif paling dominan. Hal ini dikonfirmasi oleh hasil sensitivity analysis yang menunjukkan blending ratio tidak material.
3. Faktor paling berpengaruh terhadap frekuensi klaim adalah pola siklus bulanan (Month_Sin, Month_Cos) dan autokorelasi lag (Freq_Lag_1,2,3). Faktor paling berpengaruh terhadap severitas adalah autokorelasi lag (Sev_Lag_1,2) dan pola siklus. Fitur Exposure dipertahankan sebagai deliberate design decision untuk kompatibilitas aktuarial, meski importance 0% pada data historis yang stabil.
4. Secara demografis, usia ($H=190,42$, $p<0,001$), tipe layanan ($H=789,72$, $p<0,001$), dan plan code ($H=34,51$, $p<0,001$) merupakan faktor penentu severitas yang signifikan. Rasio median klaim Inpatient terhadap Outpatient mencapai $9,94\times$.
5. Prediction interval Total Claim 2026 (80% PI: Rp132,34–149,11 miliar) divalidasi secara empiris dengan coverage 88,9% pada 9 window backtesting — melampaui target nominal 80%. P90 = Rp149,11 miliar digunakan sebagai cadangan teknis berbasis data.

4.2 Saran

4.2.1 Cadangan Teknis 2026

Model memprediksi total klaim 2026 sebesar Rp143,00 miliar (point estimate) dengan 80% Prediction Interval Rp132,34–149,11 miliar. Distribusi kuartalan tidak merata — Q1 dan Q4 secara historis menunjukkan volatilitas lebih tinggi. Berbeda dengan pendekatan buffer arbitrary, cadangan teknis yang direkomendasikan mengacu pada P90 berbasis data sebagai batas atas konservatif.

Kuartal	Point Estimate (Rp M)	P90 — Cadangan Konservatif (Rp M)
Q1 2026 (Jan–Mar)	37,13	38,70
Q2 2026 (Apr–Jun)	33,32	34,74
Q3 2026 (Jul–Sep)	36,01	37,54
Q4 2026 (Okt–Des)	36,55	38,13
Total 2026	143,00	149,11

Tabel 9. Rekomendasi Cadangan Teknis per Kuartal 2026

Cadangan P90 dihitung proporsional dari P90 total 2026 berdasarkan distribusi point estimate per kuartal. Selisih P90 vs point estimate sebesar Rp6,11 miliar (+4,3%) mencerminkan uncertainty forecast berbasis data. Coverage empiris 88,9% (Cell 6B) mengkonfirmasi PI Total Claim layak digunakan sebagai acuan. Peninjauan cadangan secara kuartalan menggunakan data aktual sangat dianjurkan.

4.2.2 Mitigasi Risiko Demografis

Kelompok usia di atas 60 tahun mendominasi portofolio dengan lebih dari 2.200 klaim dan median klaim tertinggi. Diagnosis N18.0 (gagal ginjal stadium akhir) dengan ~300 klaim merupakan penyebab klaim terbesar dan sangat terkonsentrasi pada kelompok usia senior. Plan M-003 mencatat median klaim tertinggi di antara semua plan.

- Terapkan underwriting selektif untuk peserta baru berusia >55 tahun dengan co-payment progresif atau sublimit untuk kondisi kronik tertentu.
- Kembangkan program disease management khusus untuk N18.0 mencakup monitoring rutin, edukasi gaya hidup, dan koordinasi perawatan.
- Lakukan review premi untuk profil risiko tinggi: peserta >60 tahun + Plan M-003 + metode Cashless.
- Pertimbangkan program wellness proaktif untuk kelompok 46–60 tahun sebagai investasi preventif.

4.2.3 Optimasi Biaya Layanan — Length of Stay

Length of Stay adalah prediktor numerik terkuat ($p=0,503$, $p<0,001$). Klaim Inpatient memiliki rasio median $9,94\times$ lebih tinggi dari Outpatient ($H=789,72$, $p<0,001$). Metode Cashless secara konsisten menghasilkan median klaim lebih tinggi (~Rp20 juta vs <Rp10 juta).

- Implementasikan audit klinis berbasis Length of Stay — identifikasi rawat inap >5 hari yang dapat dipersingkat melalui protokol enhanced recovery.
- Kembangkan clinical pathway per ICD utama (N18.0, C50, H26) sebagai acuan negosiasi dengan jaringan RS rekanan.
- Lakukan monitoring individual terhadap klaim Cashless Inpatient >Rp50 juta dan terapkan second opinion untuk klaim bedah elektif >Rp30 juta.

4.2.4 Perencanaan Kapasitas Musiman

Data historis menunjukkan pola musiman konsisten — Januari adalah bulan dengan frekuensi klaim tertinggi (302 klaim di Januari 2024). Model forecast mengkonfirmasi pola ini berlanjut di 2026 dengan Q1 dan Q4 menjadi periode volume tinggi.

- Siapkan kapasitas operasional tambahan di Januari–Februari dan Oktober–November melalui rekrutmen staf klaim kontrak atau aktivasi overflow provider.
- Terapkan pre-authorization ketat di Desember untuk mengurangi carry-over klaim ke Januari.
- Bangun early warning system: jika total klaim bulan berjalan melampaui forecast >15%, aktifkan review mingguan dan eskalasi ke manajemen senior.
- Negosiasikan kapasitas tempat tidur prioritas dengan 5 RS rekanan terbesar di awal tahun.

4.3 Limitasi dan Pengembangan Ke Depan

Penelitian ini memiliki beberapa limitasi yang perlu diakui. Pertama, data historis hanya mencakup 19 bulan observasi — terlalu pendek untuk menangkap siklus multi-tahun asuransi kesehatan dengan confidence tinggi, khususnya untuk horizon prediksi 17 bulan. Kedua, meski prediction interval telah dibangun dan divalidasi, coverage empiris PI Frequency dan Severity hanya 66,7% — di bawah target nominal 80% — akibat pool residual yang masih kecil (34 poin). Ketiga, model belum menginkorporasikan faktor eksternal seperti inflasi biaya medis atau tren epidemiologis nasional.

Untuk pengembangan ke depan, tim merekomendasikan: (1) ekspansi dataset ke 36–60 bulan untuk meningkatkan stabilitas model dan memperluas pool bootstrap; (2) integrasi fitur makroekonomi dan indeks inflasi biaya RS; (3) pengembangan model individual-level untuk prediksi risiko per nasabah; (4) A/B testing rekomendasi intervensi preventif untuk mengukur efektivitas aktual.